

大语言模型与生成式基础模型

基础、系统、对齐与应用

Wade Keith

2026 年 5 月 20 日

前言

本书是英文版《Large Language and Generative Foundation Models: Foundations, Systems, Alignment, and Applications》的中文可读译本。中文稿以英文版为蓝本逐章同步翻译，并在保持技术含义、章节顺序、术语边界和引用依据一致的前提下，使用更适合中文读者的表达方式组织句子。它不是“核心论点摘要”，也不是只保留结论的缩写版；它的目标是让中文读者能够沿着英文版的同一条论证路径，理解每一章为什么这样安排、每个概念解决什么问题、每种工程选择带来什么代价。

本书坚持一个基本立场：大语言模型不是一个孤立算法，而是一套由数据、目标函数、模型结构、系统实现、推理策略、评测协议和治理约束共同定义的工程系统。随着多模态大模型、统一理解-生成模型、扩散语言模型、视频生成模型和 Omni 任意到任意接口的发展，这个立场还需要进一步扩展：文本自回归只是生成式基础模型的一种重要形式，而不是整个领域的边界。理解现代基础模型的关键不是记住模型家族名称，而是能说清楚一个选择优化了什么、牺牲了什么、如何测量，以及测量本身可能在哪里失真。

本书文字、结构、例子和论证为原创教材性写作。书中研究判断尽量连接到公开论文、技术报告或课程材料。第三方幻灯片、视频转写、数据样本、代码清单和图像不作为正文内容复制。

伦理与来源说明

本书只复述公开研究中的概念、方法和结论，不复制第三方课程材料、私有数据、模型输出、代码或图像。涉及模型报告、数据集、软件项目、法规和政策文件时，均把它们作为参考来源，而不是作为可直接搬运的内容。

读者在复现实验时应特别关注数据来源、许可证、个人信息、评测污染和安全边界。一个可以训练的系统不等于一个可以发布的系统；一个可以发布的系统也不等于一个可以在高风险场景中不受约束使用的系统。

目录

第一部分 基础	1
第一章 什么使语言模型变大	2
1.1 研究对象	2
1.2 从基础模型到助手	3
1.3 本书路线	3
第二章 Token、语料与训练信号	4
2.1 数据就是规格	4
2.2 分词是建模选择	4
2.3 预训练之外的信号	5
第二部分 架构、优化与系统	6
第三章 Transformer 机制	7
3.1 张量契约	7
3.2 缩放点积注意力	7
3.3 残差、归一化与前馈层	7
第四章 从 Transformer 到 GPT	9
4.1 Decoder-only 契约	9
4.2 训练循环	9
4.3 从 logits 到文本	9
第五章 LLaMA 类架构	11
5.1 现代 decoder 默认配置	11
5.2 KV Cache 与注意力变体	11
5.3 MoE 与替代序列模型	11

第六章 优化与预训练	13
6.1 预训练问题	13
6.2 AdamW、学习率与稳定性	13
6.3 可复现训练记录	13
第七章 分布式训练系统	15
7.1 内存与并行	15
7.2 通信与吞吐	15
7.3 实现纪律	15
第八章 推理与服务	17
8.1 Prefill 与 Decode	17
8.2 KV Cache、批处理与调度	17
8.3 下一代推理系统	17
 第三部分 适配	 19
第九章 监督指令微调	20
9.1 接口转换	20
9.2 合成数据	20
9.3 局限	20
第十章 参数高效适配	22
10.1 Adapter、Prompt 与 LoRA	22
10.2 QLoRA 与量化训练	22
第十一章 领域与语言适配	23
11.1 适配是一种诊断	23
11.2 继续预训练与检索	23
11.3 领域评测	23
 第四部分 对齐、应用与评测	 25
第十二章 检索、工具与 Agent	26
12.1 RAG 作为控制系统	26
12.2 上下文工程与记忆	26

12.3 工具使用	27
12.4 Agent 工作流	27
第十三章 偏好学习与对齐	28
13.1 偏好数据	28
13.2 RLHF、PPO 与 DPO	28
13.3 DPO 之后的偏好目标	28
13.4 安全与 AI Feedback	29
第十四章 推理与测试时计算	30
14.1 推理是预算化计算	30
14.2 RLVR 与 GRPO	30
14.3 自适应测试时计算	30
第十五章 多模态与生成式基础模型	31
15.1 模态作为接口	31
15.2 统一理解与生成	31
15.3 视频、音频与 Omni 模型	32
15.4 生成模型目标	32
15.5 多模态评测与安全	33
第十六章 评测、安全与治理	34
16.1 评测是测量系统	34
16.2 人类评测与 LLM-as-Judge	34
16.3 治理	35
16.4 可解释性、遗忘与水印	35
第十七章 研究前沿与实践路线	36
17.1 为什么还需要前沿章	36
17.2 目录审查结论	36
17.3 当前仍需持续补强的方向	37
17.4 读者路线图	37
附录 A 附录：记号、实验记录与术语	38
A.1 常用记号	38
A.2 实验记录清单	38
A.3 术语表	38

第一部分

基础

第一章 什么使语言模型变大

1.1 研究对象

大语言模型的基本对象仍然是条件概率分布。给定 token 序列 $x_1, \dots, x_T$ ，自回归模型把联合概率分解为

$$p_{\theta}(x_1, \dots, x_T) = \prod_{t=1}^T p_{\theta}(x_t \mid x_{<t}).$$

训练通常最小化下一个 token 的交叉熵。这个目标看起来简单，却把语言、代码、数学、工具调用、对话格式和多模态描述都压缩进同一个预测界面。

“大”不只表示参数多。参数规模、训练 token 数、数据多样性、上下文长度、推理预算、工具能力、服务吞吐和安全约束都会改变模型行为。一个参数更小但上下文更长、检索更强、推理预算更大的系统，可能在真实任务中比一个参数更多但系统设计较弱的模型更有用。

因此，“大模型”的规模不是一个单轴数字。总参数量说明容量，激活参数量说明每个 token 实际花费的计算，训练 token 数说明模型见过多少统计证据，数据来源说明这些证据是否合法、可靠并且可复现。上下文长度说明模型一次前向可以条件化多少信息，但 KV cache、注意力代价和位置泛化决定了这个长度能否经济地服务。推理预算说明模型在预训练之后还能通过采样、检索、工具调用、验证器和搜索花多少额外计算。任何只报告参数量的比较，都无法解释现代系统的真实能力。

本书把模型看成一个“条件计算系统”。这种说法比“一个神经网络”更准确，因为同一个 checkpoint 在不同 tokenizer、chat template、解码参数、检索器、工具权限和安全过滤器下会表现出不同系统行为。基础模型学习的是文本延续分布；助手系统还要定义谁在说话、哪些指令有更高优先级、哪些内容必须拒绝、哪些外部证据可以信任，以及哪些工具可以被调用。

1.2 从基础模型到助手

基础模型通过预训练学习广泛的语言和知识模式，但它并不天然知道应该如何作为用户助手响应。后训练阶段通过监督指令微调、偏好学习、安全数据和工具协议，把基础模型转化为面向用户的系统。InstructGPT 和后续 RLHF 工作使这一点变得清晰：可用性不是预训练困惑度的直接结果，而是接口、偏好和安全目标共同塑造的结果 [56, 7]。

近年来，OpenAI o1/o3、DeepSeek-R1、Qwen3 和 Kimi K2 等系统又把“推理时间”变成产品能力的一部分。推理不再只是模型内部能力，也包括采样、搜索、验证、工具调用和预算分配 [13, 83, 33]。

这也解释了为什么预训练损失、聊天主观评分和真实部署质量之间不存在简单等价关系。预训练损失下降，可能意味着模型更好地预测了训练分布；但如果训练数据包含评测污染、错误网页、过期知识或有害模式，下游行为可能并不更可信。聊天偏好评分上升，可能说明模型语气更符合标注者期待；但它也可能学会冗长、奉承、空泛免责声明或过度拒答。真实部署则还要面对延迟、成本、权限、日志、监控和事故响应。

1.3 本书路线

第一部分讨论建模对象、token 和数据。第二部分讨论 Transformer、GPT、LLaMA 类结构、优化、分布式训练和推理服务。第三部分讨论 SFT、LoRA、QLoRA、领域和语言适配。第四部分讨论 RAG、工具、agent、偏好学习、推理型训练、多模态与生成式基础模型、评测、安全和治理。最后一章把 CS336 式从零实现纪律与 2025–2026 年前沿研究连接起来 [71]。

因此，本书虽然以大语言模型为主线，但并不把研究边界限死在纯文本模型。文本模型提供了最清晰的训练目标、系统接口和后训练范式；多模态理解模型、统一理解-生成模型、扩散/流匹配生成模型和 Omni 模型则说明，同一套数据、系统、评测和治理问题正在扩展到图像、音频、视频、语音和交互式生成。后文讨论这些模型时，会尽量避免把它们写成模型名称列表，而是把它们放回目标函数、表示、训练、服务和评测的共同框架中。

第二章 Token、语料与训练信号

2.1 数据就是规格

数据不是模型之外的附件。它定义了模型可见的语言、知识、风格、许可证边界和风险。训练语料中的重复内容会增加记忆风险；低质量网页会教会模型无意义模板；代码数据会改变推理和格式能力；多语言数据会影响 token 效率和跨语言泛化。

一个严肃的数据报告至少应记录来源、时间、许可证、语言分布、过滤规则、去重方法、敏感信息处理、合成数据生成器、评测集重叠检查和数据混合权重。没有这些信息，模型行为很难解释，评测结论也很难复现。

数据混合权重本身就是训练目标的一部分。把更多 token 分配给代码，会提升代码补全、格式遵循和某些结构化推理能力，但也会改变自然语言风格和安全风险。把更多 token 分配给数学和竞赛题，可能提升推理 benchmark，却也可能让模型在普通对话中更爱展开冗长步骤。多语言数据不仅影响语言覆盖，还影响 token fertility：同样的中文、阿拉伯文或印地语内容，如果被 tokenizer 切得更碎，就会占用更多训练和推理计算。

过滤不是单纯“清洗脏数据”。它会改变模型世界观和能力边界。过强过滤可能删掉少数语言、非正式文本、敏感但合法的讨论和真实错误案例；过弱过滤则会保留垃圾模板、个人信息、仇恨内容、恶意代码和重复材料。高水平数据管线应把过滤规则视为可审计决策，而不是一次性脚本。

2.2 分词是建模选择

Tokenizer 把文本转成离散 token。BPE、SentencePiece 和 byte fallback 等方案不只是预处理工具，它们改变序列长度、词表大小、嵌入矩阵形状和模型可学习的单位 [67, 35]。对中文、代码、数学符号和低资源语言而言，token fertility 尤其重要：同样一句话被切成更多 token，会占用更多上下文和训练计算。

Tokenizer 与模型权重绑定。更换 tokenizer 会改变 token id、特殊 token、聊天模板和长度分布。生产系统应把 tokenizer、chat template、special tokens 和模型权重一起版本化。

2.3 预训练之外的信号

监督指令数据把结构化对话序列化为 token；偏好数据把一个 prompt 下的候选回答排序；验证器数据用单元测试、数学答案或工具执行结果给出奖励；检索语料在推理时提供外部证据。它们都不是简单文本，必须记录格式、掩码、边界和评测污染风险。

评测污染是现代大语言模型研究的核心问题。模型可能见过原题、改写、答案解析、翻译版本或合成变体。任何高分都应回答一个问题：这个分数测量的是泛化能力，还是训练和开发流程已经接触过测试信息 [80]？

去重同样有多层含义。训练集内部去重可以避免重复文档被过度加权；训练集和评测集之间去重可以保护 benchmark 有效性；跨许可证去重可以避免禁止来源通过镜像或转载重新进入语料。近重复比精确重复更难处理，因为一个答案解析、论坛转载或自动翻译版本都可能携带测试信息。对于高价值评测，团队应同时做字符串级、token n-gram、文档来源和语义模板级检查。

第二部分

架构、优化与系统

第三章 Transformer 机制

3.1 张量契约

Transformer 的实现首先是张量契约。输入通常具有形状 $B \times T$ ，经过嵌入层变成 $B \times T \times d$ 。注意力层、前馈层、残差连接和归一化层都必须保持形状一致。许多训练错误不是数学思想错误，而是 mask、padding、batch 维度或 dtype 处理错误。

理解 Transformer 时，最可靠的方法不是背图，而是追踪张量。一个位置在每层都保留隐藏向量，注意力子层决定不同位置如何交换信息，MLP 子层决定每个位置内部如何变换，残差流把这些变换累积起来。只要某个实现无法清楚说明 batch 维、序列维、head 维和 hidden 维如何变化，它就很难被调试。

3.2 缩放点积注意力

对查询 Q 、键 K 、值 V ，注意力计算为

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} + M \right) V.$$

mask M 决定 token 能看见什么。因果语言模型使用上三角 mask，保证第 t 个位置不能看到未来 token。这个 mask 是自回归训练和生成的根本约束。

mask 约定是工程上最容易出错的部分之一。某些库用布尔值 True 表示允许注意，另一些库用 True 表示屏蔽；加性 mask 用一个极小负数近似 $-\infty$ ，乘性 mask 则改变概率归一化前后的语义。混合精度下，如果 softmax 前没有减去行最大值，或者 masked position 的数值不够小，就可能产生 NaN、未来信息泄漏或训练损失异常偏低。

3.3 残差、归一化与前馈层

现代 decoder 通常使用 pre-norm 结构，把归一化放在子层之前，以改善深层训练稳定性。前馈层对每个 token 独立作用，提供非线性容量。SwiGLU 等门控前馈结构在 LLaMA 类模型中很常见 [68]。

注意力权重可以辅助诊断，但不能被当作完整解释。一个 head 关注某个 token，并不证明该 token 导致了最终输出；value projection、后续层、MLP 和残差路径都可能改变或擦除信息。因此，分析 Transformer 时应结合注意力可视化、受控干预、held-out loss、下游任务和生成行为。

第四章 从 Transformer 到 GPT

4.1 Decoder-only 契约

GPT 类模型去掉 encoder-decoder 结构，只保留因果 decoder。它的统一接口是：给定前文，预测下一个 token。问答、翻译、代码补全、函数调用和对话都可以被写成同一个序列建模问题。

这种统一接口的优势是简单和可扩展。模型不需要为每个任务定义新的输出头，只要把任务、上下文、角色和目标格式写进 token 序列即可。代价是所有边界都必须被序列化：system message、user message、assistant answer、工具调用、工具返回、图像占位符、结束符和拒答格式都必须变成模型能学习的 token 模式。

4.2 训练循环

一个最小 GPT 训练循环包括：取样 token block，前向计算 logits，右移标签，计算交叉熵，反向传播，梯度裁剪，优化器更新，周期性验证和 checkpoint。损失曲线应按数据源、长度和任务切片观察，而不是只看全局平均。

训练循环的很多错误只在细节中出现。标签右移错一位会让模型预测当前 token 而不是下一个 token；padding token 没有 mask 会让模型学习填充模式；gradient accumulation 没有正确缩放 loss 会改变有效学习率；checkpoint 没有保存 optimizer state 会使恢复训练后的曲线出现跳变。小模型调试阶段应该专门写测试检查这些不变量。

4.3 从 logits 到文本

生成时，模型把 logits 转成分布。温度控制分布尖锐程度；top- k 和 top- p 控制候选集合；重复惩罚影响循环文本；stop token 和 chat template 控制响应边界。解码策略不是无关细节，它直接影响事实性、创造性、长度、成本和安全过滤。

结构化输出使解码更复杂。JSON、SQL、函数调用和工具参数都要求模型在自然语言

之外遵守语法约束。生产系统通常需要增量解析、schema validation、失败修复和安全沙盒。一个模型在自由文本中表现良好，并不代表它能稳定产生可执行、可解析、可授权的结构化动作。

第五章 LLaMA 类架构

5.1 现代 decoder 默认配置

LLaMA 类模型通常使用 pre-norm、RMSNorm、RoPE、SwiGLU、无 bias 线性层、grouped-query attention、长上下文和更复杂的数据混合 [75, 76, 21]。这些选择的价值不是单独存在的，而是在训练稳定性、推理成本和后训练兼容性之间形成组合。

RoPE 把位置信息写进 query/key 的旋转结构，使相对位置关系更自然地进入注意力分数。RMSNorm 用均方根尺度归一化隐藏状态，减少均值项处理并常用于大规模 decoder。SwiGLU 通过门控提升前馈层表达能力。GQA/MQA 减少 KV cache，但也改变注意力头共享方式。教材应该把这些组件解释为服务于稳定性、长上下文和推理成本的组合，而不是模型报告中的装饰词。

5.2 KV Cache 与注意力变体

推理时，已生成 token 的 key/value 可以缓存，避免每步重复计算全部前缀。KV cache 大小随层数、头数、维度、上下文长度和 batch 增长。GQA/MQA 通过共享 key/value 头减少缓存成本，但可能改变质量和长上下文行为 [1]。

长上下文并不只增加注意力计算，它还增加服务系统中的状态。一个请求生成到第 10,000 个 token 时，服务器需要保留大量 KV block；如果用户取消、超时或切换工具，系统还要释放或复用这些 block。架构选择和调度策略在这里相互耦合：同一个模型结构，在不同 batch、不同上下文长度和不同请求混合下，成本曲线可能完全不同。

5.3 MoE 与替代序列模型

MoE 通过稀疏激活增加总容量，每个 token 只选择部分专家。它改变了“模型大小”的含义：必须区分总参数、激活参数、路由成本和专家通信。DeepSeek-V3 与 Kimi K2 显示了 MoE 在开放权重前沿系统中的重要性 [14, 33]。

RetNet、Mamba、Mamba-2 和 Titans 等工作探索了注意力之外的长序列机制 [73, 22, 12, 9]. 但替代注意力的主张必须在相同数据、tokenizer、训练预算、上下文任务和服务负载下验证。

MoE 报告尤其要避免误导。总参数大不等于每 token 计算大，激活参数小也不等于服务便宜，因为专家路由、all-to-all 通信、负载均衡和冷专家问题都会影响吞吐。替代序列模型同样不能只报告困惑度；它们必须证明自己在检索、聚合、矛盾处理、后训练、工具调用和安全评测中仍然可靠。

第六章 优化与预训练

6.1 预训练问题

预训练配方是架构、token 预算、数据混合、优化器、精度、batch、上下文长度、硬件拓扑和停止规则的耦合选择。Scaling laws 显示损失随参数、数据和计算可预测变化；Chinchilla 进一步说明许多早期大模型相对数据量而言参数过多 [31, 26]。

预训练损失必须按 token 解释。一个 batch 中不同数据源、不同长度和不同语言的 token 贡献不同，平均 loss 可能掩盖某个语料切片已经退化。训练计划还要区分 tokens seen、unique tokens、effective batch size、sequence length 和 gradient accumulation。两个运行即使总 FLOPs 接近，也可能因为数据顺序、warmup、上下文长度或验证集不同而不可比较。

6.2 AdamW、学习率与稳定性

AdamW 将权重衰减与自适应梯度更新解耦，是现代大语言模型训练的常见优化器 [45]。Warmup 防止早期更新过大；cosine decay 或类似 schedule 控制后期收敛；梯度裁剪和混合精度处理数值稳定性。BF16 常用于大模型训练，因为指数范围比 FP16 更稳。

稳定性不是单个超参数能保证的。pre-norm、初始化、残差尺度、激活函数、attention score 范围、MoE router、长上下文位置外推和低精度格式都会影响梯度分布。训练 dashboard 应区分优化健康和模型质量：前者包括 loss、gradient norm、update norm、learning rate、clipping rate、tokens/s、显存和通信时间；后者包括代码、数学、多语言、安全、事实性和生成样例。

6.3 可复现训练记录

训练报告应记录随机种子、数据 manifest、tokenizer、模型配置、optimizer state、精度、并行策略、checkpoint 频率、验证集、损失切片、硬件和软件版本。没有这些记录，一

个损失曲线只能说明“某次运行发生过”，不能支持科学解释。

checkpoint 不是简单保存权重。要可靠恢复训练，还需要优化器状态、scheduler 状态、随机数状态、数据加载位置、并行切分配置和 tokenizer/chat template 版本。大规模运行中，失败恢复本身就是训练系统的一部分：checkpoint 太频繁会浪费 I/O，太稀疏会增加故障成本；只让 rank 0 写日志也要保证所有 worker 在 barrier 和种子上保持一致。

第七章 分布式训练系统

7.1 内存与并行

训练内存由参数、梯度、优化器状态、激活、临时 buffer 和通信 buffer 组成。数据并行复制模型并同步梯度；ZeRO/FSDP 切分参数、梯度和优化器状态 [63, 93]；tensor parallelism 切分层内矩阵；pipeline parallelism 切分深度；expert parallelism 处理 MoE 专家路由。

每种并行方式都在移动瓶颈。数据并行简单，但每个 worker 仍要保存完整模型状态；FSDP/ZeRO 节省显存，但增加 gather/scatter 和 checkpoint 复杂度；tensor parallelism 降低单卡矩阵尺寸，但引入频繁层内通信；pipeline parallelism 可以容纳更深模型，却产生 bubble 和调度复杂度；expert parallelism 适合 MoE，但 all-to-all 和负载均衡会成为核心问题。

7.2 通信与吞吐

大规模训练不是只买更多 GPU。互联带宽、all-reduce、all-to-all、pipeline bubble、activation checkpointing、kernel fusion 和数据加载都会限制吞吐。报告训练效率时，应同时给出 tokens/s、step time、MFU、GPU 利用率、显存峰值和失败恢复策略。

吞吐还必须和样本效率一起看。某个并行方案可能让 tokens/s 更高，却迫使 batch size 变大、学习率重调或数据顺序改变，最终在相同 token 预算下质量更差。系统优化的正确比较应固定训练目标和质量阈值，报告达到目标 loss 或目标 benchmark 所需的总时间、总能耗、总成本和失败次数。

7.3 实现纪律

CS336 把资源核算、GPU、kernel、Triton、并行和 scaling laws 放在核心位置，是因为语言模型工程的很多结论只有在实现后才显现 [71]。一个研究者应能从 CPU 小模型调试开始，再逐步加入 GPU、混合精度、FlashAttention、checkpointing 和分布式训练。

这种从零实现不是为了重复造轮子，而是为了识别抽象边界。使用成熟框架时，很多关键决定被隐藏在 `dataloader`、`collator`、`attention kernel`、`optimizer wrapper` 和 `distributed launcher` 中。只有写过最小版本，研究者才容易发现 `loss mask` 错误、`padding` 泄漏、通信等待、显存碎片和 `checkpoint` 不可恢复等问题。

第八章 推理与服务

8.1 Prefill 与 Decode

推理服务不是“关闭 dropout 后跑模型”。Prefill 处理 prompt，代价随输入长度增长；decode 逐 token 生成，代价随输出长度和 batch 调度变化。真实服务必须处理流式输出、取消、超时、缓存、租户隔离和安全过滤。

首 token 延迟主要受 prefill、排队和调度影响；后续 token 速度主要受 decode、KV cache 和 batch 形状影响。长文档总结、短聊天、代码补全、RAG 和 agent 工具循环对服务系统提出的压力完全不同。如果所有请求进入同一个 FIFO 队列，长上下文请求可能阻塞短请求；如果过度偏向短请求，长任务可能永远得不到足够资源。

8.2 KV Cache、批处理与调度

KV cache 是长上下文推理的主要内存压力。PagedAttention 等方法把 cache 管理变成类似操作系统内存分页的问题 [36]。服务系统需要在吞吐、首 token 延迟、尾延迟和公平性之间平衡。

调度器需要 admission control。它必须在请求进入时估计 prompt length、max new tokens、并发数和 KV cache 上限；还要在生成过程中处理提前停止、用户取消、工具等待和安全检查。结构化输出和工具调用还会引入解析器、schema validator、沙盒执行和重试逻辑，这些都应计入延迟预算。

8.3 下一代推理系统

随着 MoE、长上下文和 disaggregated serving 发展，推理服务开始分离 prefill/decode、attention/FFN 或专家路由。Frontier simulator 这类工作说明，下一代服务系统必须能模拟专家并行、跨集群路由和异构资源 [19]。

生成式多模态系统还会扩大服务问题。图像编码、视频采样、ASR、语音合成、扩散步

数、flow matching 调度和安全滤镜都可能与文本模型竞争资源。一个 Omni 系统的“延迟”不是单一模型 decode 时间，而是编码器、connector、LLM prefill、LLM decode、语音/图像/视频生成器和后处理共同构成的端到端时间。

第三部分

适配

第九章 监督指令微调

9.1 接口转换

SFT 把基础模型变成遵循指令的模型。一个样本包含系统消息、用户消息、上下文、工具观察和目标回答。训练时通常只对 assistant token 计算损失，prompt token 作为条件而非标签。

chat template 是数据格式的一部分。相同语义样本如果被写成 system/user/assistant 消息、普通 prompt-completion、工具调用 JSON 或厂商私有格式，会训练出不同边界行为。训练和推理模板不一致，是让一个本来可用的模型表现异常的常见原因。模板应明确角色、轮次结束、工具观察、图像占位符和停止条件。

9.2 合成数据

Self-Instruct、WizardLM、Orca 和 STaR 显示了合成指令、复杂任务演化、教师解释蒸馏和自举推理数据的价值 [78, 81, 49, 89]。合成数据管线必须记录生成器、prompt、采样参数、过滤规则、拒绝原因和评测重叠。

合成数据的风险随规模放大。教师模型会编造事实、写出不安全代码、误拒合法请求或把自身风格强加给学生模型。可靠管线通常需要四道门：生成 prompt 规定任务族、难度、来源和格式；自动过滤去掉重复、过短、格式错误或越界样本；任务验证器执行代码、SQL、JSON 或数学检查；人工抽样审计估计残余错误。目标不是让数据看起来多样，而是补上当前模型缺少且可验证的覆盖。

9.3 局限

SFT 学会的是示范分布。它可能提升格式和礼貌，却不一定提升真实偏好、事实性或安全性。评估 SFT 不能只看指令榜单，也要看基础能力回归、拒答边界、长上下文、多语言和代码能力。

SFT 还会产生能力遗忘。一个模型在聊天格式上变好，可能同时降低翻译、代码、事实召回、数学或低资源语言能力。训练集越窄、越合成、越单一语言，回归风险越高。严肃报告应包含 base model 与 tuned model 的对照，并在未优化任务上保留回归测试。

第十章 参数高效适配

10.1 Adapter、Prompt 与 LoRA

PEFT 的目标是减少训练参数、显存和 checkpoint 体积。Adapter 在层内加入小模块；prefix/prompt tuning 学习连续提示；LoRA 把权重更新写成低秩矩阵乘积 $\Delta W = BA$ [29]。它适合多任务共享基础模型，但不免除数据和评测责任。

LoRA 的 rank、alpha、dropout 和 target modules 都是建模选择。只调 query/value projection 成本较低，但对代码、多语言或结构化生成可能不够；同时调 attention 和 MLP 更强，但更容易过拟合或破坏基础能力。adapter 合并到基础权重后，也要重新评估量化、服务延迟和安全过滤，因为合并改变了实际部署 artifact。

10.2 QLoRA 与量化训练

QLoRA 把基础模型量化为低精度并训练 LoRA adapter，从而显著降低显存需求 [15]。量化带来效率，也带来数值误差、目标模块选择和部署合并问题。报告 PEFT 结果时，应同时给出任务指标、回归指标、显存、训练时间、checkpoint 大小和服务延迟。

PEFT 容易让实验看起来便宜，但数据和评测仍然决定可信度。一个 20MB adapter 可以携带强烈风格、过时知识或安全回归。多 adapter 系统还需要版本管理、冲突处理和权限控制：不同用户、领域或任务加载不同 adapter 时，系统必须知道它们基于哪个基础模型、哪个 tokenizer、哪个 chat template 和哪个安全策略训练。

第十一章 领域与语言适配

11.1 适配是一种诊断

模型在新领域失败，可能因为 tokenizer 对语言切分差，预训练缺少事实，风格不匹配，输出结构不稳定，或答案必须基于私有知识。不同诊断对应不同方案：继续预训练、SFT、LoRA、RAG、工具调用或拒答策略。

因此，领域适配不应从“先微调”开始，而应从失败分类开始。如果失败是术语不熟，继续预训练或领域 SFT 可能有用；如果失败是知识更新，RAG 更合适；如果失败是必须执行数据库查询或计算，工具调用更合适；如果失败是高风险边界，安全策略和人类审核比更多训练更重要。错误诊断会把问题写入权重，反而更难撤回。

11.2 继续预训练与检索

继续预训练适合稳定公开知识和领域语言模式；RAG 适合变化快、私有或需要可追溯证据的知识 [24, 38]。把私有知识写入权重可能带来隐私和更新成本；只做检索又可能受限于召回、chunking 和权限控制。

领域系统常常需要组合方案。医疗问答可以用检索提供最新指南，用 SFT 教模型如何引用证据和表达不确定性，用工具执行药物相互作用检查，用安全策略限制诊断范围。NL2SQL 可以用 schema serialization、示例检索、SFT 和执行验证共同提高可靠性。关键是把知识、行为和权限分层，而不是把所有问题都交给一次微调。

11.3 领域评测

领域评测应按实体、时间、语言、来源、任务类型和风险等级切片。医疗、法律、金融等高风险场景还需要专家审查、拒答质量、证据可追溯和上线监控。

随机切分通常不够。代码任务应按仓库切分，客服任务应按客户或时间切分，NL2SQL 应按数据库或 schema 切分，法律和医疗任务应按时间和管辖范围切分。否则模型可能只

是记住模板、实体或 schema。领域适配成功的标准也不是 benchmark 提升几分，而是模型质量、系统成本、安全边界和治理证据同时改善。

第四部分

对齐、应用与评测

第十二章 检索、工具与 Agent

12.1 RAG 作为控制系统

RAG 把检索器、reranker、上下文构造器和生成器连接起来。核心指标不是“回答看起来对”，而是检索 recall、上下文 precision、答案正确性、引用忠实度、拒答行为和延迟成本 [32, 38, 20]。

12.2 上下文工程与记忆

RAG 只是更大问题的一种形式：上下文工程。上下文工程把送入模型的全部信息载荷视为可设计、可压缩、可路由、可审计的对象，包括 system instruction、developer policy、用户请求、检索文档、对话历史、工具输出、临时 scratchpad、长期记忆和结构化状态。最新综述把这件事和早期的“prompt engineering”区分开来：真正的问题不是写一句更漂亮的提示词，而是设计一个有权限、来源、时效和失效处理的上下文管线 [47]。

这个区分很重要，因为模型足够强并不代表上下文契约正确。长提示可能包含证据，却把证据放在模型不容易利用的位置；记忆系统可能保留用户偏好，也可能保留过期或敏感信息；工具输出可能在生成时已经变旧；压缩器可能减少延迟，却删除了本应导致拒答的不确定性。因此，生产系统不应把记忆写成一个无差别文本缓冲区，而应区分用户偏好、任务状态、会话摘要、文档向量、工具观察和安全决策，并为每类记忆规定来源、更新规则、过期时间、用户可见性、删除语义和权限检查。

长上下文模型不能取代上下文工程。 ∞ Bench、RULER 和 LongBench v2 等评测显示，名义上下文长度和有效上下文利用能力并不相同，尤其在聚合、多跳推理、矛盾处理和真实长文档理解任务上差异明显 [91, 28, 8]。一个能接受 256K 或 1M token 的模型，仍然可能无法跨章节绑定证据、处理干扰信息或找到非字面匹配的事实。很多系统中，更短但经过检索、chunking、排序和状态管理的上下文，比原样塞入长文档更可靠。

12.3 工具使用

Toolformer、ReAct 和 WebGPT 等工作展示了模型调用工具、观察结果并继续推理的模式 [65, 86, 50]. 工具系统必须管理权限、参数验证、超时、重试、日志、状态和安全边界。

12.4 Agent workflow

Agent 不是一个魔法能力, 而是循环: 选择动作、执行工具、观察结果、更新状态。Kimi K2 等模型报告把 agentic coding、长上下文和工具使用作为核心能力 [33]. 评测 agent 时, 应报告成功率、工具调用次数、成本、延迟、失败模式和权限违规。

第十三章 偏好学习与对齐

13.1 偏好数据

偏好学习把单一目标回答改成候选回答比较。一个 prompt 下的 chosen/rejected 对只表达某个标注规范、标注人群和采样分布下的偏好，不是普遍真理。Reward model 学到的是这种局部偏好函数。

13.2 RLHF、PPO 与 DPO

RLHF 先训练 reward model，再用带 KL 约束的策略优化改善回答 [95, 72, 56]。PPO 是常见算法；DPO 则把偏好优化转化为更直接的监督式目标 [66, 62]。二者都可能出现过优化、奖励黑客、长度偏差和分布漂移。

13.3 DPO 之后的偏好目标

DPO 让偏好优化更像监督学习，但它并没有结束后训练目标的设计空间。后续方法继续追问：是否必须有成对比较？是否必须有冻结 reference model？是否必须显式训练 reward head？是否必须进行在线 rollout？答案取决于数据可得性、系统成本和可接受的失败风险。

KTO 把对齐写成前景理论式优化，使用 desirable/undesirable 样本而不是严格的 chosen/rejected 成对比较 [17]。这适合反馈天然以好/坏、可接受/不可接受形式收集的场景，但也要求仔细检查正负样本是否在任务、语言、风险等级和难度上平衡。ORPO 把 chosen response 的监督学习与抑制 rejected response 的 odds-ratio 惩罚放在同一个目标里，省去单独 reference model [27]。SimPO 进一步采用 reference-free 奖励和显式 margin，并用平均 log probability 缓解长度伪影 [48]。

这些方法不应被理解成单一排行榜，而应被理解成工程权衡。一个后训练报告必须说明标签类型、是否使用 reference model、如何处理回答长度、偏好数据覆盖哪些安全类别，以及哪些独立评测防止 reward hacking。偏好目标很容易优化，但如果数据定义含糊，优

化结果也很难解释。

13.4 安全与 AI Feedback

Constitutional AI 和 RLAIIF 用规则或 AI 反馈减少人工标注负担 [6, 37]. 但安全不是简单增加拒答数据。系统必须区分有害请求、合法敏感请求、误拒和越权工具行为。

第十四章 推理与测试时计算

14.1 推理是预算化计算

Chain-of-thought、自一致性、分解、程序化推理、树搜索和验证器都可以被看作测试时计算分配策略 [79, 77, 85]. 重要问题是：生成多少候选、用什么评分、花多少 token、何时调用工具、何时停止。

14.2 RLVR 与 GRPO

DeepSeek-R1 表明，基于可验证任务的大规模强化学习可以激发反思、验证和动态策略等推理行为 [13]. GRPO 用组内相对优势替代 learned critic，降低内存和复杂度，但依赖样本组多样性和奖励可靠性。RLVR 的关键风险是奖励捷径：模型可能学会通过格式或漏洞满足验证器，而不是真正稳健推理。

14.3 自适应测试时计算

测试时扩展研究正在从“多花 token 是否更强”转向“如何按难度分配预算”。综述把 test-time scaling 分解为 scale 什么、如何 scale、在哪里 scale、如何评估 [90]; 预算化推理进一步区分固定预算控制和按置信度/难度自适应分配 [3]。

第十五章 多模态与生成式基础模型

15.1 模态作为接口

多模态模型把图像、视频、音频、文档和语音接入语言模型。图像、音频、视频和传感器流并不是天然的文本 token 序列，因此多模态模型首先要解决接口问题：如何把连续信号转成语言模型可以使用的表示，同时保留任务所需的信息。CLIP 通过图文对比学习建立联合表示 [61]；Flamingo、BLIP-2、LLaVA 等系统展示了冻结视觉编码器、投影层、query transformer 和跨注意力等连接方式 [2, 39, 42]。

早期 VLM 常被理解为“给语言模型接一个视觉编码器”：编码器把图像变成 patch 或 embedding，connector 把这些表示映射到语言模型隐藏空间，语言模型再完成问答、解释或结构化输出。这个设计简单有效，但也继承了两端的弱点：视觉编码器可能忽略小字和空间关系，语言模型可能用文本先验补全并不存在的视觉事实，connector 可能为了省 token 丢掉细节。因此，多模态能力不能只看回答是否流畅，还要看它是否真正读到了图像、图表、页面或视频片段。

15.2 统一理解与生成

现在的前沿不再只是“看图回答问题”。理解模型和生成模型正在合流：一个系统可能既要读图、读文档、听语音、理解视频，又要生成图像、编辑图像、合成语音或生成视频。统一多模态理解与生成综述把相关工作分成 autoregressive、diffusion-based 和 hybrid 三类，并指出 tokenization、跨模态注意力、数据平衡和 benchmark 是共同难点 [92]。

统一模型同时面对两个方向相反的任务。理解要求忠实抽取：读清输入、绑定实体、保留空间和时间证据，并在证据不足时拒答。生成要求可控合成：创造新的媒体，遵循指令，保持一致性，并满足安全和来源要求。只用 VQA 准确率或图像审美分数评价这样的系统是不够的；它需要同时报告感知、推理、编辑、可控性、多样性、延迟和误用风险。

Janus-Pro 展示了自回归统一的一条路线：它在多模态理解和 text-to-image instruction following 上同时改进，并强调训练策略、数据规模、模型规模和生成稳定性 [10]。这类工作

说明，理解图像的表达不一定最适合生成图像；统一系统常常需要共享高层语义推理，同时在高保真生成处保留模态专门接口。

15.3 视频、音频与 Omni 模型

视频引入时间维度，音频引入采样、说话人、韵律和流式延迟。Qwen3-VL 报告了长上下文多模态输入、视频时间对齐和视觉推理能力 [60]。Qwen3-Omni 进一步把文本、图像、音频、视频理解和语音生成放进统一系统，并强调低延迟流式输出 [82]。

Omni 模型把接口问题推到更极端的位置。用户可能输入文本、截图、照片、视频、语音或它们的组合，并期待系统输出文本、语音、图像或行动。AR-Omni 代表一种更彻底的自回归方案：把文本生成、图像生成和流式语音生成放在单一 Transformer decoder 下，用统一 token 流处理任意到任意生成 [11]。这样的方案是否长期占优，不取决于概念是否优雅，而取决于它能否同时处理模态不平衡、实时性、视觉保真、语音自然度、安全策略和服务成本。

15.4 生成模型目标

自回归语言建模只是生成目标的一种。文本天然为序列，因此 next-token factorization 很自然；但图像、音频和视频可以被序列化，也可以通过扩散、流匹配或混合目标建模。Diffusion Transformer 用 transformer 替代传统 U-Net denoiser，在 latent patch 上做图像生成，并显示了可扩展性 [57]。Sora 把视觉数据压缩成 latent，再切成 spacetime patches，用 text-conditioned diffusion model 生成图像和视频 [53]。Stable Diffusion 3 相关工作使用 rectified flow transformer 进行高分辨率文本到图像合成，并强调文本 token 与图像 token 的双向交互 [16]。

对本书而言，关键不是要求读者都去实现视频生成器，而是要理解：token 预测不是基础模型的全部。Dream 7B 这类离散扩散语言模型通过迭代去噪生成文本，提供任意顺序生成、填充和质量-速度权衡 [87]。MMaDA 则把统一扩散形式用于文本推理、多模态理解和文生图，并设计面向扩散基础模型的后训练方法 [84]。MammothModa2 代表混合 AR-Diffusion 路线：自回归路径做语义规划，扩散/flow 路径做高保真图像生成与编辑 [69]。因此，高水平教材不能只讲 decoder-only LLM，还必须解释生成目标、模态表示和服务接口如何共同塑造系统能力。

15.5 多模态评测与安全

多模态评测应区分感知错误和推理错误。MMMU、MathVista、POPE、HallusionBench 和 MM-SafetyBench 分别覆盖专家知识、视觉数学、幻觉和安全风险 [88, 46, 40, 23, 43]. 视觉 prompt injection、截图隐私、OCR 错误和敏感属性推断都需要单独测试。

生成式多模态系统还要测试指令遵循、视觉保真、文字排版、对象关系、时间一致性、编辑局部性、多样性、安全过滤和来源标记。一个统一理解-生成模型不能只在生成任务上变强，却默默降低 OCR、文档问答、语音延迟或拒答边界。评测报告必须说明是否使用外部 OCR、ASR、对象检测、检索或浏览工具；否则我们无法判断分数来自模型本身，还是来自系统管线。

第十六章 评测、安全与治理

16.1 评测是测量系统

评测从问题开始：要支持什么决策？客服助手、代码 agent、医疗信息助手和教育系统需要不同指标。MMLU、HELM、GPQA、SWE-bench、HLE 和 BrowseComp 提供公共参照，但每个 benchmark 都有观念边界 [25, 41, 64, 30, 58, 54]。

长上下文、Agent 和生成式多模态系统会在传统短问答 benchmark 之外失败。长上下文评测应测试有效上下文利用，而不是只看最大输入长度；需要报告位置敏感性、干扰鲁棒性、答案证据和每个成功任务的成本 [91, 28, 8]。Agent 评测还要把模型、工具运行时、状态管理、重试策略、沙盒和预算分开看。SWE-bench 和 BrowseComp 这类评测之所以重要，是因为它们测量的不是单句语言能力，而是一个模型-工具-环境组合在约束下完成任务的能力 [30, 54]。

生成式多模态评测需要另一套证据。文生图或文生视频模型应评估指令遵循、视觉质量、文字排版、对象关系、时间一致性、编辑局部性、多样性、安全过滤和来源标记。统一理解-生成系统还需要跨任务回归检查：提升图像生成不能以牺牲 OCR、文档问答、语音延迟或安全拒答为代价。Janus-Pro、MMaDA、Sora 风格视频生成和 AR-Omni 都说明，一个平均分无法代表既能理解又能创造媒体的系统 [10, 84, 53, 11]。

16.2 人类评测与 LLM-as-Judge

人类评测需要明确 rubric、标注人资格、一致性、置信区间和失败样例。LLM-as-Judge 可以扩大规模，但会继承 judge 模型偏差、位置偏差、长度偏差和脆弱性 [94, 44]。高风险发布不能只依赖模型裁判。

16.3 治理

治理包括模型卡、数据卡、系统卡、风险框架、红队、监控、事件响应和回滚。NIST AI RMF、NIST GenAI Profile、EU AI Act、OpenAI Preparedness Framework 和 Anthropic Responsible Scaling Policy 都说明：前沿模型发布需要把能力、风险、缓解措施和残余不确定性写成可审计文档 [51, 52, 18, 55, 5]。

16.4 可解释性、遗忘与水印

治理需要技术抓手，但任何抓手都不能被夸大。机制可解释性尝试识别模型内部的特征、回路或因果路径。Anthropic 关于 monosemantic features 和 circuit tracing 的工作表明，较大模型中的某些计算结构可以被部分解释，但这仍然不是完整安全证明 [74, 4]。可解释性证据必须和干预实验、反例和下游行为测试一起使用。

Unlearning 关注另一个问题：模型训练后，如何让它停止产生或依赖特定知识、隐私数据、版权材料或危险能力。LLM unlearning 综述强调，删除声明必须同时评估保留能力、抽取抵抗、重新学习风险和连带损伤 [59]。一个模型不再回答某个记忆化 prompt，并不表示它不会通过改写、检索或微调泄露同一信息。

水印和来源工具试图识别生成内容或追踪模型输出。文本水印可以通过改变采样分布留下可检测统计信号 [34]。对多模态生成而言，来源还包括元数据、内容凭证、可见标记、模型卡和平台政策。水印可能被改写、裁剪、转码或分布漂移破坏，所以它只能作为证据层之一，而不是解决虚假信息、版权或问责问题的完整方案。

第十七章 研究前沿与实践路线

17.1 为什么还需要前沿章

前面各章覆盖了 大语言模型与生成式基础模型的主要生命周期，但前沿变化太快，不能只靠固定目录。最新系统常常在章节之间产生创新：架构变化依赖数据和训练稳定性；推理模型依赖奖励、采样和验证；多模态模型依赖服务延迟和安全策略；生成模型依赖目标函数、token/latent 表示和安全来源标记；agent 能力依赖工具协议和评测环境。

CS336 的价值在于强调从零实现：tokenizer、模型、优化器、GPU kernel、并行、scaling laws、数据处理、评测和 alignment/reasoning RL 都要亲自构建或测量 [71]。这也是本书中文版本建议的学习方式。

17.2 目录审查结论

结合 CS336 课程结构和 2025–2026 年前沿论文，本书当前 17 章结构仍然合理。把 LLM、多模态理解、图像/视频生成、agent 和治理拆成多个孤立章节，表面上会增加覆盖面，但会削弱本书最重要的教材论证：现代基础模型是一条耦合的生命周期，而不是论文主题的并列清单。因此，本轮同步采用的策略不是继续增加许多短章，而是扩大第 15 章为“多模态与生成式基础模型”，在第 12 章补上下文工程和记忆，在第 13 章补 DPO 之后的偏好目标，在第 16 章补长上下文、agentic、生成式评测以及可解释性、遗忘和水印。

这个结构的好处是主线清楚：前两章定义数据和 token；中间章节解释 Transformer、训练、系统和服务；后训练章节解释如何把基础模型变成助手；应用章节解释检索、工具、agent、推理、多模态和生成；最后用评测和治理把所有能力放回可发布系统。高水平书稿需要的不是追逐每个模型名，而是给读者稳定的分析框架。

17.3 当前仍需持续补强的方向

第一，实验作业应继续增加。读者应写 tokenizer、小 GPT、SFT collator、LoRA adapter、RAG evaluator、reward model 和 verifier loop，并报告准确率、显存、tokens/s、延迟和失败样例。

第二，服务系统应继续跟进 MoE 和 disaggregated inference。下一代推理不只是 batch scheduler，而是涉及 prefill/decode 分离、专家路由、跨集群通信和异构资源 [19]。

第三，推理章节要持续跟踪 RLVR、GRPO、预算控制和 agentic tool use。RL for LLMs 的综述已经把 PPO、DPO、GRPO、RLHF、RLAIF 和 RLVR 放进同一设计空间 [70]。

第四，多模态与生成章节要持续跟踪视频、音频、实时语音、长上下文文档理解、统一理解-生成、扩散语言模型、AR-Diffusion 混合架构和任意到任意接口。Qwen3-VL 和 Qwen3-Omni 表明，多模态正从“图像加文本”走向统一交互系统 [60, 82]；Janus-Pro、MMaDA、Dream 7B、MammothModa2 和 AR-Omni 则说明，理解与生成、文本与视觉、自回归与扩散之间的边界正在重新组织 [10, 84, 87, 69, 11]。

17.4 读者路线图

建议路线是：先实现最小 tokenizer 和 GPT；再加入资源核算和小规模训练；然后做数据清洗、去重和污染检查；接着做 SFT、LoRA、RAG、上下文工程和 typed memory；再做 DPO、KTO/ORPO/SimPO 对比、GRPO 或 verifier-guided RL；之后实现一个带 KV cache、流式输出、延迟统计和安全过滤的服务；最后增加一个多模态或生成式组件，并分别评估感知、推理、生成质量、安全和来源。每一步都问同一个问题：目标函数是什么，数据来自哪里，系统成本是多少，评测是否可信。

附录 A 附录：记号、实验记录与术语

A.1 常用记号

B 表示 batch size, T 表示序列长度, d 表示隐藏维度, V 表示词表大小, θ 表示模型参数, π_θ 表示策略模型, p_θ 表示语言模型分布。

A.2 实验记录清单

每次实验应记录：代码版本、数据版本、tokenizer、模型配置、随机种子、优化器、学习率、batch、精度、硬件、训练时间、checkpoint、验证集、指标、失败样例和结论。

A.3 术语表

基础模型 经过预训练但尚未进行指令微调或偏好优化的模型。

后训练 在预训练之后进行的 SFT、偏好优化、安全调优和领域适配。

KV Cache 推理时缓存历史 token 的 key/value 张量以降低增量生成成本。

MoE Mixture-of-Experts, 每个 token 只激活部分专家的稀疏模型结构。

RAG Retrieval-Augmented Generation, 推理时检索外部证据并生成答案的系统。

上下文工程 对送入模型的系统指令、用户请求、检索证据、工具输出、记忆和状态进行设计、压缩、路由、权限控制和审计的工程方法。

统一理解-生成模型 同时解释输入媒体并生成或编辑媒体的多模态模型或系统。

任意到任意模型 接受多种输入模态并能输出多种模态的系统，例如文本、图像、音频、语音或视频。

扩散模型 学习反转加噪过程、通过迭代去噪生成数据的生成模型，可工作在像素、token 或 latent 空间。

Rectified Flow 学习从噪声到数据的连续流的生成建模形式，常用于高分辨率视觉生成。

RLVR Reinforcement Learning with Verifiable Rewards，用可验证答案、代码测试或规则奖励训练模型。

Unlearning 训练后删除或压制特定知识或行为，同时尽量保留无关能力的技术方向。

水印 在生成内容中嵌入或检测统计信号、元数据或来源标记的方法。

评测污染 训练或开发流程接触到测试题、答案、解析或变体，导致分数高估。

参考文献

- [1] Ainslie, J., Lee-Thorp, J., de Jong, M., Zemlyanskiy, Y., Lebron, F., Sanghai, S.: Gqa: Training generalized multi-query transformer models from multi-head checkpoints. arXiv preprint arXiv:2305.13245 (2023). URL <https://arxiv.org/abs/2305.13245>
- [2] Alayrac, J.B., Donahue, J., Luc, P., Miech, A., Barr, I., Hasson, Y., Lenc, K., Mensch, A., Millican, K., Reynolds, M., Ring, R., Rutherford, E., Cabi, S., Han, T., Gong, Z., Samangooei, S., Monteiro, M., Menick, J., Borgeaud, S., Brock, A., Nematzadeh, A., Sharifzadeh, S., Binkowski, M., Barreira, R., Vinyals, O., Zisserman, A., Simonyan, K.: Flamingo: a visual language model for few-shot learning. arXiv preprint arXiv:2204.14198 (2022). URL <https://arxiv.org/abs/2204.14198>
- [3] Alomrani, M.A., Zhang, Y., Li, D., Sun, Q., Pal, S., Zhang, Z., Hu, Y., Ajwani, R.D., Valkanas, A., Karimi, R., et al.: Reasoning on a budget: A survey of adaptive and controllable test-time compute in llms. arXiv preprint arXiv:2507.02076 (2025). URL <https://arxiv.org/abs/2507.02076>
- [4] Anthropic: Circuit tracing: Revealing computational graphs in language models. Transformer Circuits Thread (2025). URL <https://transformer-circuits.pub/2025/attribution-graphs/methods.html>
- [5] Anthropic: Responsible scaling policy version 3.0. Tech. rep., Anthropic (2026). URL <https://www.anthropic.com/news/responsible-scaling-policy-v3>
- [6] Bai, Y., Kadavath, S., Kundu, S., Askell, A., Kernion, J., Jones, A., Chen, A., Goldie, A., Mirhoseini, A., McKinnon, C., et al.: Constitutional ai: Harmlessness from ai feedback. arXiv preprint arXiv:2212.08073 (2022). URL <https://arxiv.org/abs/2212.08073>
- [7] Bai, Y., Kadavath, S., Kundu, S., Askell, A., Kernion, J., Jones, A., Chen, A., Goldie, A., Mirhoseini, A., McKinnon, C., et al.: Training a helpful and harmless assistant with

- reinforcement learning from human feedback. arXiv preprint arXiv:2204.05862 (2022). URL <https://arxiv.org/abs/2204.05862>
- [8] Bai, Y., Lv, X., Zhang, J., Lyu, H., Tang, J., Huang, Z., Du, Z., Liu, X., Zeng, A., Hou, L., et al.: Longbench v2: Towards deeper understanding and reasoning on realistic long-context multitasks. arXiv preprint arXiv:2412.15204 (2024). URL <https://arxiv.org/abs/2412.15204>
- [9] Behrouz, A., Zhong, P., Mirrokni, V.: Titans: Learning to memorize at test time. arXiv preprint arXiv:2501.00663 (2025). URL <https://arxiv.org/abs/2501.00663>
- [10] Chen, X., Wu, Z., Liu, X., Pan, Z., Liu, W., Xie, Z., Yu, X., Ruan, C.: Janus-pro: Unified multimodal understanding and generation with data and model scaling. arXiv preprint arXiv:2501.17811 (2025). URL <https://arxiv.org/abs/2501.17811>
- [11] Cheng, D., Yuan, R., Li, Y., You, R., Wang, W., Nie, L., Zhang, L., Li, W.: Ar-omni: A unified autoregressive model for any-to-any generation. arXiv preprint arXiv:2601.17761 (2026). URL <https://arxiv.org/abs/2601.17761>
- [12] Dao, T., Gu, A.: Transformers are ssms: Generalized models and efficient algorithms through structured state space duality. arXiv preprint arXiv:2405.21060 (2024). URL <https://arxiv.org/abs/2405.21060>
- [13] DeepSeek-AI, Guo, D., Yang, D., Zhang, H., Song, J., Wang, P., Xu, R., Zhu, Q., Zhang, R., Ma, S., et al.: Deepseek-rl: Incentivizing reasoning capability in llms via reinforcement learning. arXiv preprint arXiv:2501.12948 (2025). URL <https://arxiv.org/abs/2501.12948>
- [14] DeepSeek-AI, Liu, A., Feng, B., Xue, B., Wang, B., Wu, B., Lu, C., Zhao, C., Deng, C., Ruan, C., et al.: Deepseek-v3 technical report. arXiv preprint arXiv:2412.19437 (2024). URL <https://arxiv.org/abs/2412.19437>
- [15] Dettmers, T., Pagnoni, A., Holtzman, A., Zettlemoyer, L.: Qlora: Efficient finetuning of quantized llms. arXiv preprint arXiv:2305.14314 (2023). URL <https://arxiv.org/abs/2305.14314>
- [16] Esser, P., Kulal, S., Blattmann, A., Entezari, R., Müller, J., Saini, H., Levi, Y., Lorenz, D., Sauer, A., Boesel, F., et al.: Scaling rectified flow transformers for high-resolution image synthesis. arXiv preprint arXiv:2403.03206 (2024). URL <https://arxiv.org/abs/2403.03206>

- [17] Ethayarajh, K., Xu, W., Muennighoff, N., Jurafsky, D., Kiela, D.: Kto: Model alignment as prospect theoretic optimization. arXiv preprint arXiv:2402.01306 (2024). URL <https://arxiv.org/abs/2402.01306>
- [18] European Union: Regulation (eu) 2024/1689 of the european parliament and of the council (artificial intelligence act) (2024). URL <https://eur-lex.europa.eu/legal-content/en/TXT/?uri=CELEX:32024R1689>
- [19] Feng, Y., Tan, X., Sew, K.H., Jiang, Y., Zhu, Y., Xu, H.: Frontier: Simulating the next generation of llm inference systems. arXiv preprint arXiv:2508.03148 (2025). URL <https://arxiv.org/abs/2508.03148>
- [20] Gan, A., Yu, H., Zhang, K., Liu, Q., Yan, W., Huang, Z., Tong, S., Hu, G.: Retrieval augmented generation evaluation in the era of large language models: A comprehensive survey. arXiv preprint arXiv:2504.14891 (2025). URL <https://arxiv.org/abs/2504.14891>
- [21] Grattafiori, A., Dubey, A., Jauhri, A., Pandey, A., Kadian, A., Al-Dahle, A., Letman, A., Mathur, A., Schelten, A., Vaughan, A., et al.: The llama 3 herd of models. arXiv preprint arXiv:2407.21783 (2024). URL <https://arxiv.org/abs/2407.21783>
- [22] Gu, A., Dao, T.: Mamba: Linear-time sequence modeling with selective state spaces. arXiv preprint arXiv:2312.00752 (2023). URL <https://arxiv.org/abs/2312.00752>
- [23] Guan, T., Liu, F., Wu, X., Xian, R., Li, Z., Liu, X., Wang, X., Chen, L., Huang, F., Yacoob, Y., Manocha, D., Zhou, T.: Hallusionbench: An advanced diagnostic suite for entangled language hallucination and visual illusion in large vision-language models. arXiv preprint arXiv:2310.14566 (2023). URL <https://arxiv.org/abs/2310.14566>
- [24] Gururangan, S., Marasovic, A., Swayamdipta, S., Lo, K., Beltagy, I., Downey, D., Smith, N.A.: Don’t stop pretraining: Adapt language models to domains and tasks. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (2020). URL <https://arxiv.org/abs/2004.10964>
- [25] Hendrycks, D., Burns, C., Basart, S., Zou, A., Mazeika, M., Song, D., Steinhardt, J.: Measuring massive multitask language understanding. arXiv preprint arXiv:2009.03300 (2020). URL <https://arxiv.org/abs/2009.03300>

- [26] Hoffmann, J., Borgeaud, S., Mensch, A., Buchatskaya, E., Cai, T., Rutherford, E., de Las Casas, D., Hendricks, L.A., Welbl, J., Clark, A., et al.: Training compute-optimal large language models. arXiv preprint arXiv:2203.15556 (2022). URL <https://arxiv.org/abs/2203.15556>
- [27] Hong, J., Lee, N., Thorne, J.: Orpo: Monolithic preference optimization without reference model. arXiv preprint arXiv:2403.07691 (2024). URL <https://arxiv.org/abs/2403.07691>
- [28] Hsieh, C.P., Sun, S., Krizan, S., Acharya, S., Rekesh, D., Jia, F., Ginsburg, B.: Ruler: What’s the real context size of your long-context language models? arXiv preprint arXiv:2404.06654 (2024). URL <https://arxiv.org/abs/2404.06654>
- [29] Hu, E.J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., Chen, W.: Lora: Low-rank adaptation of large language models. arXiv preprint arXiv:2106.09685 (2021). URL <https://arxiv.org/abs/2106.09685>
- [30] Jimenez, C.E., Yang, J., Wettig, A., Yao, S., Pei, K., Press, O., Narasimhan, K.: Swe-bench: Can language models resolve real-world github issues? arXiv preprint arXiv:2310.06770 (2023). URL <https://arxiv.org/abs/2310.06770>
- [31] Kaplan, J., McCandlish, S., Henighan, T., Brown, T.B., Chess, B., Child, R., Gray, S., Radford, A., Wu, J., Amodei, D.: Scaling laws for neural language models. arXiv preprint arXiv:2001.08361 (2020). URL <https://arxiv.org/abs/2001.08361>
- [32] Karpukhin, V., Oguz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., Yih, W.t.: Dense passage retrieval for open-domain question answering. arXiv preprint arXiv:2004.04906 (2020). URL <https://arxiv.org/abs/2004.04906>
- [33] Kimi Team, Bai, Y., Bao, Y., Charles, Y., Chen, C., Chen, G., Chen, H., Chen, J., Chen, N., Chen, R., et al.: Kimi k2: Open agentic intelligence. arXiv preprint arXiv:2507.20534 (2025). URL <https://arxiv.org/abs/2507.20534>
- [34] Kirchenbauer, J., Geiping, J., Wen, Y., Katz, J., Miers, I., Goldstein, T.: A watermark for large language models. In: International Conference on Machine Learning (2023). URL <https://arxiv.org/abs/2301.10226>
- [35] Kudo, T., Richardson, J.: Sentencepiece: A simple and language independent subword tokenizer and detokenizer for neural text processing. arXiv preprint arXiv:1808.06226 (2018). URL <https://arxiv.org/abs/1808.06226>

- [36] Kwon, W., Li, Z., Zhuang, S., Sheng, Y., Zheng, L., Yu, C.H., Gonzalez, J.E., Zhang, H., Stoica, I.: Efficient memory management for large language model serving with pagedattention. arXiv preprint arXiv:2309.06180 (2023). URL <https://arxiv.org/abs/2309.06180>
- [37] Lee, H., Phatale, S.M.X., Lu, K., Mesnard, T., Bishop, C., Carbune, V., Rastogi, A.: Rlaif: Scaling reinforcement learning from human feedback with ai feedback. arXiv preprint arXiv:2309.00267 (2023). URL <https://arxiv.org/abs/2309.00267>
- [38] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Kuttler, H., Lewis, M., Yih, W.t., Rocktaschel, T., et al.: Retrieval-augmented generation for knowledge-intensive nlp tasks. arXiv preprint arXiv:2005.11401 (2020). URL <https://arxiv.org/abs/2005.11401>
- [39] Li, J., Li, D., Savarese, S., Hoi, S.: Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. arXiv preprint arXiv:2301.12597 (2023). URL <https://arxiv.org/abs/2301.12597>
- [40] Li, Y., Du, Y., Zhou, K., Wang, J., Zhao, W.X., Wen, J.R.: Evaluating object hallucination in large vision-language models. arXiv preprint arXiv:2305.10355 (2023). URL <https://arxiv.org/abs/2305.10355>
- [41] Liang, P., Bommasani, R., Lee, T., Tsipras, D., Soylu, D., Yasunaga, M., Zhang, Y., Narayanan, D., Wu, Y., Kumar, A., Newman, B., Yuan, B., Yan, B., Zhang, C., Cosgrove, C., Manning, C.D., Re, C., Acosta-Navas, D., Hudson, D.A., Zelikman, E., Durmus, E., Ladhak, F., Rong, F., Ren, H., Yao, H., Wang, J., Santhanam, K., Orr, L., Zheng, L., Yuksekgonul, M., Suzgun, M., Kim, N., Guha, N., Chatterji, N., Khattab, O., Henderson, P., Huang, Q., Chi, R., Xie, S.M., Santurkar, S., Ganguli, S., Hashimoto, T., Icard, T., Zhang, T., Chaudhary, V., Wang, W., Li, X., Mai, Y., Zhang, Y., Koreeda, Y.: Holistic evaluation of language models. arXiv preprint arXiv:2211.09110 (2022). URL <https://arxiv.org/abs/2211.09110>
- [42] Liu, H., Li, C., Wu, Q., Lee, Y.J.: Visual instruction tuning. arXiv preprint arXiv:2304.08485 (2023). URL <https://arxiv.org/abs/2304.08485>
- [43] Liu, X., Zhu, Y., Gu, J., Lan, Y., Yang, C., Qiao, Y.: Mm-safetybench: A benchmark for safety evaluation of multimodal large language models. arXiv preprint arXiv:2311.17600 (2023). URL <https://arxiv.org/abs/2311.17600>

- [44] Liu, Y., Iter, D., Xu, Y., Wang, S., Xu, R., Zhu, C.: G-eval: Nlg evaluation using gpt-4 with better human alignment. arXiv preprint arXiv:2303.16634 (2023). URL <https://arxiv.org/abs/2303.16634>
- [45] Loshchilov, I., Hutter, F.: Decoupled weight decay regularization. International Conference on Learning Representations (2019). URL <https://arxiv.org/abs/1711.05101>
- [46] Lu, P., Bansal, H., Xia, T., Liu, J., Li, C., Hajishirzi, H., Cheng, H., Chang, K.W., Galley, M., Gao, J.: Mathvista: Evaluating mathematical reasoning of foundation models in visual contexts. arXiv preprint arXiv:2310.02255 (2023). URL <https://arxiv.org/abs/2310.02255>
- [47] Mei, L., Yao, J., Ge, Y., Wang, Y., Bi, B., Cai, Y., Liu, J., Li, M., Li, Z.Z., Zhang, D., et al.: A survey of context engineering for large language models. arXiv preprint arXiv:2507.13334 (2025). URL <https://arxiv.org/abs/2507.13334>
- [48] Meng, Y., Xia, M., Chen, D.: Simpo: Simple preference optimization with a reference-free reward. arXiv preprint arXiv:2405.14734 (2024). URL <https://arxiv.org/abs/2405.14734>
- [49] Mukherjee, S., Mitra, A., Jawahar, G., Agarwal, S., Palangi, H., Awadallah, A.: Orca: Progressive learning from complex explanation traces of gpt-4. arXiv preprint arXiv:2306.02707 (2023). URL <https://arxiv.org/abs/2306.02707>
- [50] Nakano, R., Hilton, J., Balaji, S., Wu, J., Ouyang, L., Kim, C., Hesse, C., Jain, S., Kosaraju, V., Saunders, W., et al.: Webgpt: Browser-assisted question-answering with human feedback. arXiv preprint arXiv:2112.09332 (2021). URL <https://arxiv.org/abs/2112.09332>
- [51] National Institute of Standards and Technology: Artificial intelligence risk management framework (ai rmf 1.0). Tech. rep., National Institute of Standards and Technology (2023). URL <https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.100-1.pdf>
- [52] National Institute of Standards and Technology: Artificial intelligence risk management framework: Generative artificial intelligence profile. Tech. rep., National Institute of Standards and Technology (2024). URL <https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.600-1.pdf>

- [53] OpenAI: Video generation models as world simulators. Technical report (2024). URL <https://openai.com/research/video-generation-models-as-world-simulators>
- [54] OpenAI: Browsecomp: A simple yet challenging benchmark for browsing agents. arXiv preprint arXiv:2504.12516 (2025). URL <https://arxiv.org/abs/2504.12516>
- [55] OpenAI: Our updated preparedness framework. Tech. rep., OpenAI (2025). URL <https://openai.com/index/updating-our-preparedness-framework/>
- [56] Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C.L., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Ray, A., et al.: Training language models to follow instructions with human feedback. arXiv preprint arXiv:2203.02155 (2022). URL <https://arxiv.org/abs/2203.02155>
- [57] Peebles, W., Xie, S.: Scalable diffusion models with transformers. Proceedings of the IEEE/CVF International Conference on Computer Vision (2023). URL <https://arxiv.org/abs/2212.09748>
- [58] Phan, L., Gatti, A., Han, Z., Li, N., Hu, J., Zhang, H., Zhang, C.B.C., Shaaban, M., Ling, J., Shi, S., Choi, M., et al.: Humanity’s last exam. arXiv preprint arXiv:2501.14249 (2025). URL <https://arxiv.org/abs/2501.14249>
- [59] Qiu, R., Tan, J., Pu, J., Wang, H., Gao, X.S., Sun, F.: A survey on unlearning in large language models. arXiv preprint arXiv:2510.25117 (2025). URL <https://arxiv.org/abs/2510.25117>
- [60] Qwen Team: Qwen3-vl technical report. arXiv preprint arXiv:2511.21631 (2025). URL <https://arxiv.org/abs/2511.21631>
- [61] Radford, A., Kim, J.W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., Sutskever, I.: Learning transferable visual models from natural language supervision. Proceedings of the 38th International Conference on Machine Learning (2021). URL <https://arxiv.org/abs/2103.00020>
- [62] Rafailov, R., Sharma, A., Mitchell, E., Ermon, S., Manning, C.D., Finn, C.: Direct preference optimization: Your language model is secretly a reward model. arXiv preprint arXiv:2305.18290 (2023). URL <https://arxiv.org/abs/2305.18290>
- [63] Rajbhandari, S., Rasley, J., Ruwase, O., He, Y.: Zero: Memory optimizations toward training trillion parameter models. Proceedings of the International Conference for

- High Performance Computing, Networking, Storage and Analysis (2020). URL <https://arxiv.org/abs/1910.02054>
- [64] Rein, D., Hou, B.L., Stickland, A.C., Petty, J., Pang, R.Y., Dirani, J., Michael, J., Bowman, S.R.: Gpqa: A graduate-level google-proof q&a benchmark. arXiv preprint arXiv:2311.12022 (2023). URL <https://arxiv.org/abs/2311.12022>
- [65] Schick, T., Dwivedi-Yu, J., Dessì, R., Raileanu, R., Lomeli, M., Zettlemoyer, L., Cancedda, N., Scialom, T.: Toolformer: Language models can teach themselves to use tools. Advances in Neural Information Processing Systems (2023). URL <https://arxiv.org/abs/2302.04761>
- [66] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., Klimov, O.: Proximal policy optimization algorithms. arXiv preprint arXiv:1707.06347 (2017). URL <https://arxiv.org/abs/1707.06347>
- [67] Sennrich, R., Haddow, B., Birch, A.: Neural machine translation of rare words with subword units. arXiv preprint arXiv:1508.07909 (2016). URL <https://arxiv.org/abs/1508.07909>
- [68] Shazeer, N.: Glu variants improve transformer. arXiv preprint arXiv:2002.05202 (2020). URL <https://arxiv.org/abs/2002.05202>
- [69] Shen, T., Wan, X., Chen, T., Zhang, R., Pan, J., Lu, D., Lei, F., Lu, Z., Yang, Y., Cheng, C., et al.: Mammothmoda2: A unified ar-diffusion framework for multimodal understanding and generation. arXiv preprint arXiv:2511.18262 (2025). URL <https://arxiv.org/abs/2511.18262>
- [70] Srivastava, S.S., Aggarwal, V.: A technical survey of reinforcement learning techniques for large language models. arXiv preprint arXiv:2507.04136 (2025). URL <https://arxiv.org/abs/2507.04136>
- [71] Stanford University: CS336: Language modeling from scratch. Course website (2026). URL <https://cs336.stanford.edu/>. Accessed 2026-05-20
- [72] Stiennon, N., Ouyang, L., Wu, J., Ziegler, D.M., Lowe, R., Voss, C., Radford, A., Amodei, D., Christiano, P.F.: Learning to summarize with human feedback. Advances in Neural Information Processing Systems (2020). URL <https://arxiv.org/abs/2009.01325>

- [73] Sun, Y., Dong, L., Huang, S., Ma, S., Xia, Y., Xue, J., Wang, J., Wei, F.: Retentive network: A successor to transformer for large language models. arXiv preprint arXiv:2307.08621 (2023). URL <https://arxiv.org/abs/2307.08621>
- [74] Templeton, A., Conerly, T., Marcus, J., Lindsey, J., Bricken, T., Chen, B., Pearce, A., Citro, C., Ameisen, E., Jones, A., et al.: Scaling monosemanticity: Extracting interpretable features from claude 3 sonnet. Transformer Circuits Thread (2024). URL <https://transformer-circuits.pub/2024/scaling-monosemanticity/>
- [75] Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M.A., Lacroix, T., Roziere, B., Goyal, N., Hambro, E., Azhar, F., et al.: Llama: Open and efficient foundation language models. arXiv preprint arXiv:2302.13971 (2023). URL <https://arxiv.org/abs/2302.13971>
- [76] Touvron, H., Martin, L., Stone, K., Albert, P., Almahairi, A., Babaei, Y., Bashlykov, N., Batra, S., Bhargava, P., Bhosale, S., et al.: Llama 2: Open foundation and fine-tuned chat models. arXiv preprint arXiv:2307.09288 (2023). URL <https://arxiv.org/abs/2307.09288>
- [77] Wang, X., Wei, J., Schuurmans, D., Le, Q., Chi, E.H., Narang, S., Chowdhery, A., Zhou, D.: Self-consistency improves chain of thought reasoning in language models. arXiv preprint arXiv:2203.11171 (2022). URL <https://arxiv.org/abs/2203.11171>
- [78] Wang, Y., Kordi, Y., Mishra, S., Liu, A., Smith, N.A., Khashabi, D., Hajishirzi, H.: Self-instruct: Aligning language models with self-generated instructions. arXiv preprint arXiv:2212.10560 (2022). URL <https://arxiv.org/abs/2212.10560>
- [79] Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E.H., Le, Q.V., Zhou, D.: Chain-of-thought prompting elicits reasoning in large language models. arXiv preprint arXiv:2201.11903 (2022). URL <https://arxiv.org/abs/2201.11903>
- [80] Xu, C., Guan, S., Greene, D., Kechadi, M.T.: Benchmark data contamination of large language models: A survey. arXiv preprint arXiv:2406.04244 (2024). URL <https://arxiv.org/abs/2406.04244>
- [81] Xu, C., Sun, Q., Zheng, K., Geng, X., Zhao, P., Feng, J., Tao, C., Jiang, D.: Wizardlm: Empowering large language models to follow complex instructions. arXiv preprint arXiv:2304.12244 (2023). URL <https://arxiv.org/abs/2304.12244>

- [82] Xu, J., Guo, Z., Hu, H., Chu, Y., Wang, X., He, J., Wang, Y., Shi, X., He, T., Zhu, X., et al.: Qwen3-omni technical report. arXiv preprint arXiv:2509.17765 (2025). URL <https://arxiv.org/abs/2509.17765>
- [83] Yang, A., Li, A., Yang, B., Zhang, B., Hui, B., Zheng, B., Yu, B., Gao, C., Huang, C., Lv, C., et al.: Qwen3 technical report. arXiv preprint arXiv:2505.09388 (2025). URL <https://arxiv.org/abs/2505.09388>
- [84] Yang, L., Tian, Y., Li, B., Zhang, X., Shen, K., Tong, Y., Wang, M.: Mmada: Multi-modal large diffusion language models. arXiv preprint arXiv:2505.15809 (2025). URL <https://arxiv.org/abs/2505.15809>
- [85] Yao, S., Yu, D., Zhao, J., Shafran, I., Griffiths, T.L., Cao, Y., Narasimhan, K.: Tree of thoughts: Deliberate problem solving with large language models. arXiv preprint arXiv:2305.10601 (2023). URL <https://arxiv.org/abs/2305.10601>
- [86] Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., Cao, Y.: React: Synergizing reasoning and acting in language models. arXiv preprint arXiv:2210.03629 (2023). URL <https://arxiv.org/abs/2210.03629>
- [87] Ye, J., Xie, Z., Zheng, L., Gao, J., Wu, Z., Jiang, X., Li, Z., Kong, L.: Dream 7b: Diffusion large language models. arXiv preprint arXiv:2508.15487 (2025). URL <https://arxiv.org/abs/2508.15487>
- [88] Yue, X., Ni, Y., Zhang, K., Zheng, T., Liu, R., Zhang, G., Stevens, S., Jiang, D., Ren, W., Sun, Y., Wei, C., Yu, B., Yuan, R., Sun, R., Yin, M., Zheng, B., Yang, Z., Liu, Y., Huang, W., Sun, H., Su, Y., Chen, W.: Mmmu: A massive multi-discipline multimodal understanding and reasoning benchmark for expert agi. arXiv preprint arXiv:2311.16502 (2023). URL <https://arxiv.org/abs/2311.16502>
- [89] Zelikman, E., Wu, Y., Mu, J., Goodman, N.: Star: Bootstrapping reasoning with reasoning. Advances in Neural Information Processing Systems (2022). URL <https://arxiv.org/abs/2203.14465>
- [90] Zhang, Q., Lyu, F., Sun, Z., Wang, L., Zhang, W., Guo, Z., Wang, Y., King, I., Liu, X., Ma, C.: What, how, where, and how well? a survey on test-time scaling in large language models. arXiv preprint arXiv:2503.24235 (2025). URL <https://arxiv.org/abs/2503.24235>

- [91] Zhang, X., Chen, Y., Hu, S., Xu, Z., Chen, J., Hao, M.K., Han, X., Thai, Z.L., Wang, S., Liu, Z., Sun, M.: ∞ bench: Extending long context evaluation beyond 100k tokens. arXiv preprint arXiv:2402.13718 (2024). URL <https://arxiv.org/abs/2402.13718>
- [92] Zhao, S., Zhang, X., Guo, J., Hu, J., Duan, L., Fu, M., Chng, Y.X., Wang, G.H., Chen, Q.G., Xu, Z., et al.: Unified multimodal understanding and generation models: Advances, challenges, and opportunities. arXiv preprint arXiv:2505.02567 (2025). URL <https://arxiv.org/abs/2505.02567>
- [93] Zhao, Y., Gu, A., Varma, R., Luo, L., Huang, C.C., Xu, M., Wright, L., Shojanazeri, H., Ott, M., Shleifer, S., Desmaison, A., Balioglu, C., Damania, P., Nguyen, B., Chauhan, G., Hao, Y., Mathews, A., Li, S.: Pytorch fsdp: Experiences on scaling fully sharded data parallel. Proceedings of the VLDB Endowment (2023). URL <https://arxiv.org/abs/2304.11277>
- [94] Zheng, L., Chiang, W.L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E.P., Zhang, H., Gonzalez, J.E., Stoica, I.: Judging llm-as-a-judge with mt-bench and chatbot arena. arXiv preprint arXiv:2306.05685 (2023). URL <https://arxiv.org/abs/2306.05685>
- [95] Ziegler, D.M., Stiennon, N., Wu, J., Brown, T.B., Radford, A., Amodei, D., Christiano, P., Irving, G.: Fine-tuning language models from human preferences. arXiv preprint arXiv:1909.08593 (2019). URL <https://arxiv.org/abs/1909.08593>